

伪世界纸片角色照明 修正版完整推导

从正典深度、相对 HDR 与伪世界可见性出发，建立面向二维纸片角色的 reference final gather、缺失方向闭包和运行时 L2 probe 管线。

文档版本	2026-07-21 修正版
PDF 生成	2026-07-22
适用范围	固定二维背景 / 推导深度 / 纸片角色 / 离线烘焙
核心目标	以明确可控的先验解决角色受光、遮挡、背光和环境融入

目录

0. 先给结论

1. 问题边界：哪些是输入，哪些永远无法从单张图推出

- 1.1 正典输入
- 1.2 不可观测量

2. 伪世界坐标为什么足以做光线追踪

- 2.1 从像素与深度定义伪世界
- 2.2 q 空间与展示用伪世界空间的等价性
- 2.3 正确的“屏幕空间 raymarch”实际仍是伪世界 raymarch

3. 从深度到可用于遮挡的伪几何

- 3.1 深度的目标不是微小纹理，而是可见性拓扑
- 3.2 可见表面网格
- 3.3 可见表面、光照碰撞体和角色遮挡不是同一个对象

4. 角色：显示几何与着色法线解耦

- 4.1 角色颜色的物理含义
- 4.2 显示平面保持不变
- 4.3 可调主法线
- 4.4 围绕主法线生成身体隆起

5. LDR 到 HDR：恢复的是相对场景辐射，不是假装知道绝对 nit

- 5.1 基础性辐射
- 5.2 局部高动态增益

6. 背景像素为什么可以作为命中后的入射光

- 6.1 角色上的渲染方程
- 6.2 可见背景命中是 terminal radiance

7. 原画面中的间接光、恢复光源与双重记账

- 7.1 为什么背对蜡烛不能全黑
- 7.2 增量发光的唯一记账规则
- 7.3 坐标基必须统一

8. 缺失背面和画外方向：一个不重复记账的补全估计器

- 8.1 为什么必须补全

8.2 相机侧折叠

8.3 局部低频闭包 J_{bar}

8.4 正确的分段 trace 定义

8.5 补全误差能说到什么程度

9. 逐角色像素的参考 final gather

9.1 余弦半球采样

9.2 这个 reference 的准确含义

9.3 必须输出的逐像素诊断

10. 从 reference 到 L2 probe cache

10.1 先缓存方向辐射，再做 Lambert 卷积

10.2 分量缓存

10.3 正确的空间插值

10.4 probe 不得“吸附后冒充原位置”

10.5 插值误差边界

11. 最终运行时着色式

12. 误差账本：每个近似究竟会错在哪里

13. 缓存与工具的数据契约

13.1 单一数据源

13.2 失效规则

13.3 推荐运行时载荷

14. 验证：必须先通过的解析与项目场景测试

14.1 解析测试

14.2 项目场景测试

15. 由推导直接得到的修正清单

16. 计算量、运行时边界与成本约束

16.1 复杂度

16.2 与日成本上限 100 的关系

16.3 表达能力上限

17. 最终成立的理论链

参考与现有项目决策

0. 先给结论

本项目能够成立的目标，不是从单张二维绘制背景中恢复唯一的真实三维世界与绝对物理光照；那个问题信息不足，不可辨识。项目真正需要、也确实能够稳定求解的目标是：

在一套由正典深度、遮挡边界、伪世界标定和 HDR 标定共同定义的“可控伪世界”中，估计纸片角色每个着色点从场景可见表面接收到的条件辐照度，并用明确的先验补全单张图没有提供的方向域。

这套目标直接解决当前问题：

1. 角色不再把原素材颜色当作最终自发光颜色，而把它当作漫反射反照率；没有光时会暗，有暖光时会暖，背光时直接光会消失，但仍可接收场景中已经存在的间接光。
2. 所有可见命中都在伪世界中判断，屏幕上重合但深度相距很远的像素不会错误互相照明。
3. 角色显示几何仍可保持面向相机，避免纸片走样；着色主法线与显示平面彻底解耦，可以单独旋转，边缘隆起法线也围绕这个主法线生成。
4. 背景像素的线性 HDR 出射辐射作为命中后的入射辐射。对近似漫反射背景，这一步已经包含画面里原有的直接光和间接光，命中后不应继续递归，否则会重复计算。
5. 单张图没有背面。缺失方向采用“原射线优先、只在 miss 后折叠、折叠仍失败再用局部低频闭包”的分段估计，不再把真实命中和补全结果叠加。
6. 参考结果使用逐角色像素的伪世界 final gather；运行时结果是同一估计器的 L2 球谐压缩和空间插值，而不是另一套光照逻辑。

因此，本方案的“正确”含义是：在已声明的伪世界几何与补全先验下，积分、坐标、能量记账和压缩彼此一致；不是声称从一张图恢复了客观真实世界。

1. 问题边界：哪些是输入，哪些永远无法从单张图推出

1.1 正典输入

对每个场景，唯一允许进入照明烘焙的正典输入为：

- 背景图 $C_{ldr}(s)$ ，其中 $s=(s_x, s_y)$ 是背景像素坐标；
- 深度编辑器产出的正典深度 $D(s)$ ，不是照明工具私自重新推导的第二份深度；
- 从背景像素、深度到伪世界的标定参数 K_{pseudo} ；
- 用于遮挡/碰撞重建的边界、断边、地面延拓和厚度参数；
- 场景曝光 $sceneExposureEV$ 、局部增益图 $gainEV(s)$ 及其生成参数；
- 角色颜色 $\rho_{tex}(u, v)$ 、透明度 $\alpha(u, v)$ 、角色位置/尺寸和着色法线参数。

深度和 HDR 都必须缓存到编辑器工程中，并携带输入内容哈希、算法版本和参数哈希。任一上游输入改变时，旧缓存只能标记为过期，不能静默继续使用。

1.2 不可观测量

单张绘制背景没有提供：

- 被前景遮住的几何；
- 场景背面的几何和材质；
- 背面朝角色方向的出射辐射；
- 真实相机相对于现实世界的焦距、姿态和绝对尺度；
- 每个背景像素的真实反照率、法线和 BRDF；
- LDR 截断以前的绝对物理亮度；
- 画面之外的天空、墙面和其他光源。

这些量不存在唯一解。任何算法对它们给出的数值都只能是先验或条件估计。因此本文以后使用三个不同词：

- 恢复：由已有数据和确定坐标变换唯一算出的量；
- 标定：人为选择一个等价类中的尺度或曝光基准；
- 补全：对不可观测域施加明确先验得到的估计。

这一区分非常关键。只要补全被写进公式、能关闭、能对比、能报告置信度，它就是工程上可用的近似；把补全说成真实恢复，才会让后续验证失去标准。

2. 伪世界坐标为什么足以做光线追踪

2.1 从像素与深度定义伪世界

令深度编辑器最终输出的、经过标定的深度为 $D(s)$ 。采用当前工具的正交伪投影约定，可写成：

$$q(s) = \begin{bmatrix} (s_x - c_x)/p_{pu} \\ (c_y - s_y)/p_{pu} \\ D(s) \end{bmatrix}, \quad (1)$$

其中 p_{pu} 是每伪世界单位对应的像素数， (c_x, c_y) 是伪投影中心。若编辑器以后使用更一般的投影，只需把式 (1) 替换为正典反投影函数

$$q = \Pi_{pseudo}^{-1}(s, D(s); K_{pseudo}). \quad (2)$$

所有照明代码只能调用这一个正典函数，不能各自重新解释深度。

2.2 q 空间与展示用伪世界空间的等价性

编辑器为了让人理解，可能再用一个正交矩阵 R 把 q 旋到展示用伪世界坐标：

$$x = Rq + t, \quad R^T R = I. \quad (3)$$

于是对任意两点和两个方向：

$$\|x_1 - x_2\| = \|q_1 - q_2\|, \quad (4)$$

$$(Ra) \cdot (Rb) = a \cdot b. \quad (5)$$

距离、夹角、余弦项和射线相交关系全部保持。因此 RT 可以直接在 `q` 空间做，不需要知道真实相机相对于真实世界的方向。编辑器里的三维相机只是观察这套伪几何的工具，不参与光照定义。

必须注意，式 (4) 只对刚体变换成立。`p_pu` 和深度尺度共同选择了一个伪度量；若三个轴被不一致地缩放，距离平方衰减和立体角会改变。也就是说，绝对世界尺度不可恢复，但一旦项目选定伪尺度，所有几何、光源面积和衰减都必须使用同一个尺度。

2.3 正确的“屏幕空间 raymarch” 实际仍是伪世界 raymarch

从角色点 `q_0` 沿伪世界方向 `omega_q` 发射：

$$r(t) = q_0 + t\omega_q, \quad t > \varepsilon. \quad (6)$$

每一步把 `r(t)` 投到背景像素：

$$s(t) = \Pi_{pseudo}(r(t)). \quad (7)$$

再检测射线深度与正典表面深度的有符号差：

$$g(t) = r_z(t) - D(s(t)). \quad (8)$$

出现合法符号跨越后，在 `t` 上二分或割线细化交点。步长必须以伪世界距离 `t` 定义，不能简单沿屏幕像素走直线；后者会让屏幕方向替代三维方向，正是“看起来射线很多却命中街道”的常见错误。

若已经从深度生成了断边正确的三角网格，直接做 ray-triangle intersection 更清楚。两种实现必须通过同一组解析场景测试，并给出一致结果。

3. 从深度到可用于遮挡的伪几何

3.1 深度的目标不是微小纹理，而是可见性拓扑

角色照明最敏感的不是每个像素的厘米级深度误差，而是：

1. 前后景边界是否切开；
2. 墙、柱、门沿等应保持的边是否发生错误剪切；
3. 角色所在自由空间与其他空间是否被错误连通；
4. 射线是否会穿过本应遮挡的薄表面。

因此深度处理的优先级应为：

遮挡边界正确 > 结构切变正确 > 低频深度合理 > 像素级细节.

(9)

所谓“垂直约束”不是把野外全部压成平面，而是在已经识别为人造竖直结构的区域中，对线段消失方向、平行性和局部平面施加约束；野外仍保留由深度和遮挡关系给出的坡度与前后层次。

3.2 可见表面网格

每个有效像素产生顶点 $q(s)$ 。相邻四像素只在满足下列条件时连接三角形：

- 两侧不跨语义或显著遮挡边；
- 深度跳变量低于与局部尺度相关的阈值；
- 三角形法线、面积和长宽比没有退化；
- 人工/自动断边掩码允许连接。

这避免把前景人物轮廓、墙边和远处天空用长三角形缝起来。对于照明来说，“少连一个可疑三角形”通常比“跨遮挡边错误连通”安全。

3.3 可见表面、光照碰撞体和角色遮挡不是同一个对象

定义：

- S_{vis} ：由图像与深度直接得到的可见前表面；
- O_{light} ：用于光线传播的占据体；
- O_{sprite} ：游戏里角色前后遮挡使用的正典深度/碰撞表示。

O_{light} 可以由 S_{vis} 沿不可见侧添加有限厚度，并对明确的地面区域进行受约束延拓。它是为了阻止射线从薄壳背面瞬间漏出，不代表恢复了真实墙厚。厚度必须与场景伪尺度相关，并在编辑器中可见、可调。

不得用“整张图下方都是地面”这类全局平面假设填平野外。地面延拓只对有地面证据且与角色可达区域连通的部分生效。其余空洞保留为未知域，交给第 8 节的方向补全，而不是捏造几何。

4. 角色：显示几何与着色法线解耦

4.1 角色颜色的物理含义

角色贴图 RGB 定义为漫反射反照率：

$$\rho(u, v) = \text{clamp}(\text{EOTF}(C_{\text{char}}(u, v)), 0, 1). \quad (10)$$

它不再直接作为最终显示颜色。角色自身默认不发光：

$$L_e^{\text{char}} = 0. \quad (11)$$

因此在零入射光下，角色线性输出确实为黑；但室内背景的可见墙面、地面和物体本来就带有非零出射辐射，final gather 会把这些原有的直接与间接照明带给角色，所以“站在蜡烛背后”只应失去蜡烛的直接项，不应失去全部环境光。

4.2 显示平面保持不变

令角色显示 quad 的中心/脚点为 $\mathbf{q}_c$ ，平面切向为 $\mathbf{t}_1, \mathbf{t}_2$ ，面向伪相机的几何法线为 $\mathbf{n}_0$ ，满足

$$\mathbf{t}_1 \times \mathbf{t}_2 = \mathbf{n}_0. \quad (12)$$

显示顶点仍为：

$$\mathbf{q}_{\text{display}}(u, v) = \mathbf{q}_c + x(u)\mathbf{t}_1 + y(v)\mathbf{t}_2. \quad (13)$$

这样角色轮廓不会因为光照法线改变而透视走样。

4.3 可调主法线

定义用户可调的单位主法线 $\mathbf{m}_q$ 。它与 $\mathbf{n}_0$ 完全独立：

$$\|\mathbf{m}_q\| = 1. \quad (14)$$

编辑器可以用 yaw/pitch、球面摇杆或三分量输入控制它。所有 UI 参数最终必须存成同一 $\mathbf{q}$ 坐标中的 $\mathbf{m}_q$ ，禁止有的地方存世界空间、有的地方存相机空间。

按式 (1) 的轴向约定，面向伪相机的基础法线可以写为 $\mathbf{n}_0 = (0, 0, -1)$ （如果工程采用相反深度正方向则整体取反）；展示空间法线是 $\mathbf{Rn}_0$ 。积分若在 $\mathbf{q}$ 空间进行，采样半球、主法线和光线方向必须全部留在 $\mathbf{q}$ 空间；若在展示 world 空间进行，则三者必须全部乘 $\mathbf{R}$ 。不能只转换其中一项。

m_q 不是从纸片几何恢复出的真实人体法线，而是项目显式选择的着色法线先验。它的意义是“角色身体正面主要朝哪个方向接收光”。这正是纸片角色在不增加美术资源的条件下所需要的自由度。

4.4 围绕主法线生成身体隆起

定义可调隆起函数 $b(x, y)$ 。若先在原显示法线周围构造局部表面

$$q_b(x, y) = q_c + xt_1 + yt_2 + b(x, y)n_0, \quad (15)$$

则其未归一化法线为：

$$\tilde{n}_b = n_0 - \frac{\partial b}{\partial x}t_1 - \frac{\partial b}{\partial y}t_2. \quad (16)$$

设 $Q(n_0 \rightarrow m_q)$ 为把 n_0 最短弧旋转到 m_q 的旋转，则最终逐像素着色法线为：

$$n_s(u, v) = \text{normalize}[Q(n_0 \rightarrow m_q)\tilde{n}_b(u, v)]. \quad (17)$$

这保证中心区域法线接近 m_q ，越靠轮廓，法线越向切线方向倾斜。角色仍是平面图像，但受光轮廓更接近有体积的人体。

隆起函数可采用低成本椭球：

$$b(x, y) = a\sqrt{\max\left(0, 1 - \frac{x^2}{r_x^2} - \frac{y^2}{r_y^2}\right)}. \quad (18)$$

实践中需对透明轮廓距离场进行调制，否则矩形 quad 四角会产生不属于身体的法线。最重要的实现约束是：法线必须由当前的角色宽、高、透明轮廓、隆起量和主法线实时或在同次烘焙中导出，不能继续读取一张按固定隆起量烘死、但运行时又允许改变隆起参数的法线图。

若只希望改变法线而不改变射线起点，式 (15) 仅用于求导，实际发射点仍用式 (13)。若希望减少自身平面感，可允许光照代理点沿 n_0 有少量 b 位移，但该位移不改变显示轮廓，并必须作为独立开关。

5. LDR 到 HDR：恢复的是相对场景辐射，不是假装知道绝对 nit

5.1 基础线性辐射

对背景颜色先做 sRGB EOTF：

$$C_{lin}(s) = \text{EOTF}_{sRGB}(C_{ldr}(s)). \quad (19)$$

选择参考白 `L_w=100` 作为项目内部亮度规约，并应用逐场景曝光：

$$L_0(s) = L_w C_{lin}(s) 2^{EV_{scene}}. \quad (20)$$

这里 `100` 不是从图片恢复出的真实 100 nit，而是统一单位的 gauge。把它换成其他常数，只要同步改变角色显示标定，最终相对结果等价。

5.2 局部高动态增益

语义模型只产生潜在发光载体候选；局部对比、亮核、近环溢光与环境能量证据决定 `g(s)=gainEV(s)`。最终：

$$L_{hdr}(s) = L_0(s) 2^{g(s)}. \quad (21)$$

为防止直接项和环境项重复记账，将其严格拆成：

$$\Delta L_e(s) = L_0(s) \left(2^{g(s)} - 1 \right), \quad (22)$$

$$L_{hdr}(s) = L_0(s) + \Delta L_e(s). \quad (23)$$

`L_0` 是原画面已经表现出的基础出射辐射；`Delta L_e` 是为恢复被 LDR 压缩的发光核心而额外加入的能量。编辑器必须能同时查看：

- 基础线性图 `L_0`；
- 增益图 `g`；
- 增量发光图 `Delta L_e`；
- 合成 HDR `L_hdr`；
- 带 EV 或相对 nit 标尺的 false-color 图。

`sceneExposureEV` 必须真正进入式 (20)，不能只存在 UI/配置里。背景显示与角色显示必须经过同一个展示曝光和 tone mapper；否则即使线性光照正确，也会产生角色“贴上去”的显示错觉。

6. 背景像素为什么可以作为命中后的入射光

6.1 角色上的渲染方程

角色不自发光，采用 Lambert BRDF：

$$f_r = \frac{\rho}{\pi}. \quad (24)$$

角色点 $\mathbf{q}$ 、法线 $\mathbf{n}$ 的出射辐射为：

$$L_o^{char}(\mathbf{q}, \mathbf{n}) = \frac{\rho(\mathbf{q})}{\pi} \int_{\Omega^+(\mathbf{n})} L_i(\mathbf{q}, \omega) (\mathbf{n} \cdot \omega) d\omega. \quad (25)$$

定义辐照度：

$$E(\mathbf{q}, \mathbf{n}) = \int_{\Omega^+(\mathbf{n})} L_i(\mathbf{q}, \omega) (\mathbf{n} \cdot \omega) d\omega. \quad (26)$$

于是：

$$L_o^{char} = \frac{\rho}{\pi} E. \quad (27)$$

6.2 可见背景命中是 terminal radiance

从 $\mathbf{q}$ 沿 ω 首次命中背景可见表面 $\mathbf{x}$ 。在真实渲染方程中：

$$L_i(\mathbf{q}, \omega) = L_o^{scene}(\mathbf{x}, -\omega). \quad (28)$$

单张图只测到了 $L_o^{scene}(\mathbf{x}, \omega_{cam})$ 。项目采用背景表面近似漫反射、绘制结果代表其稳定局部出射颜色的先验：

$$L_o^{scene}(\mathbf{x}, -\omega) \approx L_o^{scene}(\mathbf{x}, \omega_{cam}) \approx L_{hdr}(\mathbf{s}_x). \quad (29)$$

因此射线第一次命中可见表面后，直接读取 HDR 背景颜色就是此条路径的入射辐射估计。

这一步已经包含原画面中该表面的自发光、直接照明和间接照明之和。对同一个可见命中继续向场景递归追踪，会重新计算已经被画进像素的能量，造成双算。项目采用单向耦合：背景照亮角色，角色不反向改变背景。所以生产 reference 是 **one-bounce final gather with terminal scene radiance**，不是对背景再做无限次 path tracing。

式 (29) 的误差来自背景的镜面高光和强视角依赖笔触。由于项目没有背景 BRDF 与其他观察方向，这个误差无法被算法消除，只能通过低频积分、增益裁决和置信度控制减弱。

7. 原画面中的间接光、恢复光源与双重记账

7.1 为什么背对蜡烛不能全黑

设原画面基础辐射为 L_0 。墙面与地面的 L_0 已经画出了蜡烛照亮室内后的结果。角色背对蜡烛时：

- 蜡烛新增直接项的余弦为零或被遮挡；
- 但指向墙、桌、地面的射线仍会读取非零 L_0 ；
- 所以角色仍接收原画面已经包含的环境反弹光。

这正是 final gather，而不是“只命中灯才有光”。如果结果仍接近纯黑，首先应检查射线方向、角色主法线、深度相交与 miss 闭包，不能用任意环境常量掩盖坐标错误。

7.2 增量发光的唯一记账规则

ΔL_e 是算法人为恢复出来、原 LDR 基础图中没有完整保留的额外能量。生产模式采用 NEE 时：

1. 普通 final-gather 命中只读取 L_0 ；
2. ΔL_e 只通过显式光源采样加入；
3. 同一 ΔL_e 不得同时出现在普通射线命中与 NEE 中；
4. 手工太阳同理，只能有一个入口。

把发光掩码离散为小面元 j ，面积 A_j 、中心 x_j 、法线 n_j 、增量出射辐射 $\Delta L_{\{e,j\}}$ 。从角色点到面元：

$$\ell_j = \frac{x_j - q}{\|x_j - q\|}, \quad r_j = \|x_j - q\|. \quad (30)$$

小面元近似的新增直接辐照度为：

$$E_{emit}^{dir}(q, n) \approx \sum_j \Delta L_{e,j} A_j V(q, x_j) \frac{\max(n \cdot \ell_j, 0) \max(n_j \cdot (-\ell_j), 0)}{\max(r_j^2, r_{min}^2)}. \quad (31)$$

对蜡烛火焰、窗洞等无法可靠确定法线的发光体，可以明确采用双面发射先验，把第二个余弦替换为 1；这不是物理恢复，而是比错误使用可见壳法线更稳定的内容假设。大面积或近距离光源不能只用一个中心点，必须细分或对面元面积采样。

ΔL_e 的新增间接反弹默认不另算。原因是 L_0 已含原画面所表达的间接照明，而无法从单图判断其中缺失了多少由裁剪高光导致的反弹。若以后确需补强，只能作为独立、可关闭、能量受限的低频二次项，不能混进当前 reference 后再称为真值。

7.3 坐标基必须统一

若面元和角色点在展示 world 空间计算出方向 ell_{world} ，而 probe 的球谐系数与角色法线都在 q 空间，则投影球谐以前必须变换：

$$\ell_q = R^T \ell_{world}. \quad (32)$$

否则 NEE 看起来有数值，方向却随展示旋转而错误。所有 SH 系数必须在元数据中声明其坐标基，当前项目固定为 `q-space`。

8. 缺失背面和画外方向：一个不重复记账的补全估计器

8.1 为什么必须补全

单张深度只给出了从伪相机可见的 2.5D 壳层。角色半球采样中有些方向会：

- 命中 `S_vis` 或有限厚度碰撞体；
- 穿出图像边界；
- 朝向相机一侧，没有任何可观测背景表面；
- 进入被遮挡的未知空间。

将所有 miss 设为黑是一个极强的“画外世界绝对无光”先验，会系统性低估照度；给所有 miss 加同一个全局常量又会抹掉室内外和墙体两侧差异。因此需要空间相关、方向相关、可关闭的补全。

8.2 相机侧折叠

`q` 空间中的伪相机平面法线 `v_cam` 是由投影约定已知的，不需要真实相机姿态。对朝向缺失相机侧的方向，可在图像平面上反射：

$$F(\omega) = \omega - 2(\omega \cdot v_{cam})v_{cam}. \quad (33)$$

它表达一个局部镜像先验：不可见相机侧的辐射分布，近似为对应可见侧的辐射分布。它在封闭室内、角色贴近可见墙面时有一定合理性，在强单侧开口、背后是室外的场景会有偏差，因此不能覆盖真实命中。

8.3 局部低频闭包 `J_bar`

在自由空间布置稀疏 closure probes。每个 probe 发射方向样本，只保留真实命中的 terminal radiance，用带正则的 L2 球谐拟合得到空间相关的低频辐射函数：

$$c^*(p) = \arg \min_c \sum_{i \in H_p} w_i \left\| \sum_{l=0}^2 \sum_{m=-l}^l c_{lm} Y_{lm}(\omega_i) - L_i \right\|^2 + \lambda \sum_{l=1}^2 \sum_{m=-l}^l l(l+1) \|c_{lm}\|^2. \quad (34)$$

其中 `H_p` 只包含真实命中样本，不把 miss 当黑色训练样本。于是：

$$\bar{J}(p, \omega) = \max \left(0, \sum_{l=0}^2 \sum_{m=-l}^l c_{lm}(p) Y_{lm}(\omega) \right). \quad (35)$$

空间插值只在同一自由空间连通分量中进行。拟合的有效命中数、方向覆盖度和残差共同形成 `confidence_J(p)`；低置信位置必须在查看器中显色。

这不是 radiosity 求解，也不能声称误差会按平均反照率的幂次收敛。它是“给定附近可见命中后，对缺失方向辐射的低频条件估计”。

8.4 正确的分段 trace 定义

令 `Hit(q, omega)` 返回原射线的第一合法命中，`Omega_cam` 为确实朝向缺失相机侧、允许使用折叠先验的方向集合。再定义闭包查询方向：

$$\psi(\omega) = \begin{cases} F\omega, & \omega \in \Omega_{cam}; \\ \omega, & \omega \notin \Omega_{cam}. \end{cases} \quad (36)$$

生产 terminal estimator 为：

$$T(q, \omega) = \begin{cases} L_{base}(Hit(q, \omega)), & \text{原射线命中;} \\ L_{base}(Hit(q, F\omega)), & \text{原射线 miss, } \omega \in \Omega_{cam}, \text{ 且折叠射线命中;} \\ \bar{J}(q, \psi(\omega)), & \text{其他 miss;} \end{cases} \quad (37)$$

其中 NEE 开启时 `L_base=L_0`；NEE 关闭的诊断模式才允许 `L_base=L_hdr`。

三条分支互斥，因此真实命中、折叠和 `J_bar` 可以共存，且不会双算。旧说法“局部折叠和 `J_bar` 不能共存”过强；真正不能做的是在一条已经命中的样本上再次叠加折叠值或闭包值。

8.5 补全误差能说到什么程度

设未知真实方向辐射为 `L_true`，缺失方向集合为 `Omega_miss`，则补全对某法线的偏差精确写为：

$$B(q, n) = \int_{\Omega_{miss}} [\hat{L}(q, \omega) - L_{true}(q, \omega)] \max(n \cdot \omega, 0) d\omega. \quad (38)$$

没有背面观测时，这个误差在对抗性场景中没有有限的普适上界。项目能做的是：缩小 `Omega_miss`、使用局部先验、报告覆盖率和置信度，并在低置信区域回落到旧光环境曲线或人工环境项。不能用一个未经证明的几何级数替代这个事实。

9. 逐角色像素的参考 final gather

9.1 余弦半球采样

对角色样本点 $\mathbf{q}$ 和式 (17) 的法线 $\mathbf{n}$ ，在其上半球以

$$p(\omega) = \frac{\mathbf{n} \cdot \omega}{\pi} \quad (39)$$

进行余弦重要性采样。辐照度的无偏 Monte Carlo 估计为：

$$\hat{E}_{base+closure}(q, n) = \frac{1}{N} \sum_{i=1}^N \frac{T(q, \omega_i)(\mathbf{n} \cdot \omega_i)}{p(\omega_i)} = \frac{\pi}{N} \sum_{i=1}^N T(q, \omega_i). \quad (40)$$

加入显式增量光源和手工方向光：

$$\hat{E}(q, n) = \hat{E}_{base+closure}(q, n) + E_{emit}^{dir}(q, n) + E_{sun}^{dir}(q, n). \quad (41)$$

角色线性输出：

$$L_{char}^{ref}(u, v) = \beta \frac{\rho(u, v)}{\pi} \odot \max[\hat{E}(q(u, v), \mathbf{n}_s(u, v)), 0]. \quad (42)$$

β 是角色素材与场景内部辐射单位之间的显示/材质标定，不是再次改变场景曝光。一个合理初值是选定中性参考位置 $\mathbf{q}_{ref}$ ：

$$\beta = \frac{\pi}{Y(E(\mathbf{q}_{ref}, m_q))}, \quad (43)$$

使中性灰照明下角色大致保持素材原亮度，同时保留环境色偏。最后角色与背景共同经过同一个曝光与 tone mapper。

9.2 这个 reference 的准确含义

式 (42) 是在以下条件下的参考解：

- 正典伪几何固定；
- 背景可见面采用式 (29) 的 terminal-radiance 先验；
- 缺失域采用式 (37) 的补全；
- HDR 与 NEE 按第 7 节只记一次；
- 角色为 Lambert 纸片着色代理。

它是缓存、SH 和运行时滤镜必须逼近的“项目 reference”，不是现实世界 ground truth。若 reference 看起来不对，应逐项查看命中、miss、折叠、闭包、NEE 与法线贡献；不能先调缓存让它看起来好，再倒推 reference。

9.3 必须输出的逐像素诊断

每次 reference 计算至少能显示：

- 原始命中率；
- 折叠挽回率；
- `J_bar` 使用率；
- NEE 可见光源数与能量；
- 原命中平均距离；
- 每个角色像素的主法线；
- `E_base`、`E_closure`、`E_emit`、`E_sun` 分量；
- 最终线性 HDR 和 tone-mapped 结果。

射线三维查看器显示的线段必须就是积分实际使用的 `q_0+t omega_q`，而不是另行生成的示意线。

10. 从 reference 到 L2 probe cache

10.1 先缓存方向辐射，再做 Lambert 卷积

在自由空间 probe `p` 对方向辐射 `L(p, omega)` 投影实球谐：

$$L_{lm}(p) = \int_{S^2} L(p, \omega) Y_{lm}(\omega) d\omega. \quad (44)$$

Lambert 余弦核是 zonal kernel。截断到 `l<=2` 时：

$$E(p, n) \approx \sum_{l=0}^2 \sum_{m=-l}^l A_l L_{lm}(p) Y_{lm}(n), \quad (45)$$

其中

$$A_0 = \pi, \quad A_1 = \frac{2\pi}{3}, \quad A_2 = \frac{\pi}{4}. \quad (46)$$

常量环境 `L(p, omega)=L_c` 必须满足：

$$E(p, n) = \pi L_c, \quad (47)$$

而不是 $L_c/2$ 或 L_c 。这条解析测试可以直接抓出旧推导中额外 $1/(2\pi)$ 所造成的归一化错误。

L2 不是逐方向辐射的高精度重建，但 Lambert 卷积会强烈低通。Ramamoorthi-Hanrahan 的原始结果是：对任意物理光照，9 系数近似的平均误差低于约 3%、最大可到约 9%；自然环境通常平均低于 1%、最大低于约 5%。因此它适合角色漫反射，不适合锐利镜面。

离线实现应直接保存预卷积系数 $G_{lm}(p) := A_l L_{lm}(p)$ ，这样运行时只需计算 $\sum G_{lm} Y_{lm}(n)$ 。manifest 必须明确文件中保存的是 $radiance_SH=L_{lm}$ 还是 $irradiance_SH=G_{lm}$ ；当前项目运行时载荷统一选择后者，禁止再乘一次 A_l 。

10.2 分量缓存

为调试和防双算，probe 至少逻辑上分为：

$$G_{lm}^{total} = G_{lm}^{base} + G_{lm}^{closure} + G_{lm}^{mee} + G_{lm}^{sun}. \quad (48)$$

生产文件可以在验证后合并分量，但构建产物和查看器必须能拆开。NEE 的方向在投影以前必须按式 (32) 转到 q 基。

10.3 正确的空间插值

对查询点所在网格单元的 8 个角点，先插值带符号的 SH 系数：

$$\hat{G}_{lm}(q) = \frac{\sum_{k=1}^8 w_k(q) m_k(q) G_{lm,k}}{\sum_{k=1}^8 w_k(q) m_k(q) + \epsilon}. \quad (49)$$

$m_k(q)$ 是有效性/连通性掩码：

- 角点必须在自由空间；
- 角点与查询点必须属于同一自由空间连通分量；
- 从查询点到角点不能跨越显著遮挡面。

然后用式 (45) 评估，并只在最终总辐照度上 clamp：

$$E(q, n) = \max \left(0, \sum_{lm} \hat{G}_{lm}(q) Y_{lm}(n) \right). \quad (50)$$

不能先对每个 probe 的球谐 lobe clamp，再做三线性插值；clamp 是非线性的，会破坏系数之间的抵消关系并引入额外能量。

10.4 probe 不得“吸附后冒充原位置”

若规则网格点落入实体，不能把它移动到最近自由点计算，却仍把结果存回原规则坐标；这会把墙另一侧的光照带进当前单元。正确方案是：

1. 只在真实自由位置建立 probe；

2. 为规则单元存 8-bit 有效角点掩码和连通分量；
3. 插值时按式 (49) 归一化有效权重；
4. 单元没有有效角点时，回落到同一自由分量最近 probe 或低置信环境值；
5. 墙两侧即使欧氏距离很近，也不能互相插值。

每单元 1 byte 的角点有效掩码成本很低，却直接解决跨墙漏光。

10.5 插值误差边界

在无遮挡变化且辐照度二阶连续的单元内，三线性插值误差满足通常的二阶量级：

$$\|E - \hat{E}\| = O(h^2 \max \|\nabla^2 E\|), \quad (51)$$

其中 h 是 probe 间距。但在阴影边界、门洞、薄墙附近， E 不光滑，式 (51) 不适用。这里必须靠更密 probe、连通掩码和局部可见性修正，不能靠增加一个全局插值阶数解决。

11. 最终运行时着色式

对角色像素 (u, v) ：

1. 从角色在游戏场景中的位置映射到背景像素；
2. 用正典深度/地面深度和同一标定得到 $q(u, v)$ ；
3. 用式 (17) 得到 q 空间着色法线 $n_s(u, v)$ ；
4. 用式 (49) 插值 probe 系数；
5. 用式 (50) 评估各照明分量；
6. 做 Lambert 着色；
7. 与背景共用展示曝光和 tone mapper。

统一公式为：

$$L_{char}(u, v) = \beta \frac{\rho(u, v)}{\pi} \odot \max [E_{base} + E_{closure} + E_{emit}^{dir} + E_{sun}^{dir}, 0] S_{contact}. \quad (52)$$

$S_{contact}$ 是角色脚部或与场景表面接触处的局部可见性/美术修正，范围应小、可独立关闭。它不能承担整体把角色压暗的职责；整体融入必须来自前四个辐照度项和统一 tone mapping。

若某场景缓存不存在、哈希过期或角色位置置信度过低，则返回 `null` 并回落旧光环境系统。旧曲线和 probe 光照不得同时相乘。

12. 误差账本：每个近似究竟会错在哪里

误差来源	数学影响	项目处理	能否消除
遮挡断边错误	改变 <code>Hit</code> ，造成数量级错误和漏光	正典断边网格、三维射线检查、连通掩码	可显著降低
低频深度/伪尺度错误	改变距离、立体角和 NEE 的 $1/r^2$	统一标定、典型场景验证、参数可调	只能标定
背面几何缺失	扩大 <code>Omega_miss</code>	有限厚度、受约束地面延拓、保留未知域	无法真实恢复
背面辐射缺失	式 (38) 的闭包偏差	原射线优先、折叠、局部 <code>J_bar</code> 、置信度	无普适上界
背景非 Lambert	式 (29) 的方向偏差	低频积分、限制极端高光、分离发光增量	无额外视图时不可消除
HDR 绝对尺度	所有辐射乘统一常数	<code>sceneExposureEV</code> 与 <code>beta</code> 定标	绝对 nit 不可辨识
发光 NEE 面元近似	近场/大光源误差	面元细分、可见性、 <code>r_min</code> 仅作数值保护	可收敛降低
L2 SH 截断	丢失高频角向变化、可能有负瓣	Lambert 限定、最终 clamp、reference 对比	升阶可降低但成本增加
probe 空间插值	平滑区二阶误差，阴影边无平滑界	密度、连通掩码、局部可见性	可降低
角色 albedo 假设	原素材自带的手绘明暗会被当作材质	<code>beta</code> 、可选低频去光照预处理；本轮不改素材	无材质分解时不可消除
主法线先验	与真实人体形态不一致	编辑器可调、围绕主法线的轮廓隆起	属于设计自由度

任何效果汇报都必须同时给出误差来源对应的诊断图，不能只给最终合成图。

13. 缓存与工具的数据契约

13.1 单一数据源

角色照明工具不得私自重新推导深度或重新自动标定。它只能读取场景深度编辑器导出的版本化包：

```
scene_lighting_source/  
  manifest.json  
  background.png  
  depth.*  
  projection.json  
  collision.json  
  hdr_base.*  
  hdr_gain.*  
  hdr_manifest.json
```

实际文件格式可按现有工程调整，但语义必须唯一。`manifest` 至少包含：

- 背景内容哈希；
- 深度输入哈希、模型/算法版本和编辑参数哈希；
- 投影/标定版本与参数；
- 碰撞重建版本与参数；
- HDR 输入哈希、`sceneExposureEV`、增益参数和公式版本；
- 坐标基、轴向、单位、颜色空间和通道定义。

13.2 失效规则

满足任一条件即标记过期：

- 背景内容哈希变化；
- 深度或断边参数变化；
- 伪投影/尺度变化；
- `sceneExposureEV` 或 `gainEV` 变化；
- 主公式版本变化；
- `probe`、折叠、闭包、NEE 或 SH 参数变化。

编辑器应区分：

- `source stale`：深度/HDR 源缓存过期；
- `lighting stale`：源有效，但照明缓存尚未按新参数重烘；
- `runtime stale`：烘焙有效，但游戏导出载荷落后。

背景文件不能使用“若目标已存在就不覆盖”的策略；必须按内容哈希决定复用或更新。

13.3 推荐运行时载荷

运行时保留：

- `lighting.json`：坐标桥、probe 网格、版本、内容哈希、分量开关、显示标定；
- L2 RGB 系数：每 probe 每分量 $9 \times 3 \times \text{fp16} = 54 \text{ byte}$ ；
- `probe`/单元有效掩码与自由空间连通分量；
- 必要的地面查询深度或位置映射数据。

若 P 个 `probe` 分别保存 base、closure、NEE 三组，系数裸数据为：

$$Size_{SH} = P \times 9 \times 3 \times 2 \times 3 = 162P \text{ byte.} \quad (53)$$

正式导出前可把稳定且不需独立调试的分量合并，从而降到 `54P` byte；体素、三角网格、参考射线和高精度 HDR 只留在编辑器/离线构建侧。

14. 验证：必须先通过的解析与项目场景测试

14.1 解析测试

1. 常量辐射场：任意法线均应得到 $E = \pi \cdot L$ ；reference、SH 和运行时误差分别报告。
2. 单方向光：旋转主法线时应严格呈 $\max(n \cdot l, 0)$ ，背面直接项为零。
3. 坐标旋转不变性：同时用 R 旋转点、方向和法线，输出必须不变。
4. 深度分离：屏幕同位置、深度不同的两个面，不得因二维邻近互相命中。
5. 薄墙测试：墙两侧 probe 不得插值串光；关闭连通掩码应能复现错误。
6. 折叠互斥：原射线命中时，fold 与 J_{bar} 贡献必须严格为零。
7. NEE 记账：NEE on 使用 $L_0 + \text{direct } \Delta L_e$ ；NEE off 使用 ray-hit L_{hdr} 。两个模式不能同时加入 ΔL_e 。
8. 法线/隆起一致性：改变角色宽高或 bulge 后，中心法线仍等于 m_q ，轮廓法线连续更新。

14.2 项目场景测试

至少选择：

- 室内烛火：角色在火焰前、侧、后；验证背后只有直接项消失，墙面环境光仍在；
- 城市街道：验证大量半球射线能命中道路、墙面与街道物件，三维查看器中路径与统计一致；
- 狭窄门洞/墙角：验证 probe 连通和遮挡边，不跨墙漏光；
- 野外起伏地形：验证没有被错误压成全平地面，前景遮挡和坡面仍存在；
- 强发光窗口：验证 HDR 增量、NEE 双算开关和主法线转向。

每个场景固定输出以下对比：

1. 原始角色直接贴图；
2. 只用 L_0 的 reference；
3. $L_0 + \text{closure}$ ；
4. $L_0 + \text{closure} + \text{NEE}$ ；
5. reference 与 L2 cache 并排及误差热图；
6. 主法线至少三个方向的对比；
7. 原命中/折叠/闭包射线三维分类图；
8. 线性 HDR false-color 与最终 tone-mapped 合成。

15. 由推导直接得到的修正清单

以下不是可选优化，而是让现有实现与上述公式一致的必要修正：

1. `sceneExposureEV` 必须实际乘进 HDR 基础辐射，而非只存在参数面板。
2. CPU NEE 的 world-space 光方向在投影 SH 前必须转成 `q-space`。
3. 删除“实体内 probe 吸附到最近自由点、结果仍占原网格位置”的做法，改用有效角点与自由空间连通掩码。

- 隐藏区域补色应描述为 L_0 的局部/调和延拓先验，不得宣称是从隐藏 albedo 精确算出的 final gather；发光增量不得被无条件涂抹进隐藏区域。NEE 开启时， J_{bar} 也只能从 L_0 的真实命中拟合，不能把 ΔL_e 藏进闭包后又追加 NEE。
- 角色法线由当前角色尺寸、轮廓、bulge 与主法线共同生成；显示 quad 朝相机不再强迫着色法线朝相机。
- 深度、背景、标定与 HDR 全部改读场景深度编辑器的正典缓存，照明工具停止维护平行数据源。
- 背景与缓存更新全部由内容哈希驱动，禁止旧 `background.png` 静默残留。
- J_{bar} probe 使用真实空间布局 and 同连通分量插值，不得用数组扫描顺序伪装空间取样。
- NEE 标注为“有限发光面元直接项近似”，不再标成 exact。
- reference 与 probe 必须共享完全相同的 HDR 拆分、trace 分段、坐标基和法线模型；否则两者对比没有意义。

16. 计算量、运行时边界与成本约束

16.1 复杂度

令角色有效着色像素数为 C 、每像素参考射线数为 N 、平均 march 步数为 S 、probe 数为 P 、每 probe 方向数为 D 、显式发光面元数为 L ，则：

- 逐像素 reference: $O(CNS + CL)$ ；
- probe 烘焙: $O(PDS + PL)$ ；
- 运行时 L2 查询：每查询点 8 个邻居、9 个 RGB 系数的插值和 9 项 SH 评估，为固定 $O(1)$ ；
- 运行时不携带深度 RT、体素、三角网格、语义模型或 HDR 恢复模型。

reference 的职责是定方法和缓存，不对所有角色、所有帧实时运行。正式游戏只消费离线 probe。编辑器交互预览可以先用低分辨率、低 SPP，停止拖动参数后再累积到高 SPP；这不会改变估计器，只改变方差。

16.2 与日成本上限 100 的关系

按项目给出的日成本上限 100，本方案不要求新增角色素材、动画、场景贴图或付费三维重建，也不要求运行时部署分割模型。成本集中在一次性 agent 实现和本地离线计算；每张场景允许人工调整的量被限制为曝光、增益裁决、深度/断边标定和少量照明先验参数。

在这个预算下，优先级必须是：

- 先修坐标基、曝光、双算、probe 连通和动态法线这些确定性错误；
- 再用少量典型场景建立 reference 与缓存误差门；
- 最后才增加 probe 密度、SPP 或可选的低频二次补光；
- 不用额外美术资源掩盖 reference 本身的错误。

实际预处理秒数、峰值内存和单场景产物尺寸必须由工具在每次 bake 后写入 manifest，不能在理论文档中捏造固定值。至少记录 $C/N/S/P/D/L$ 、各阶段墙钟时间、峰值 RSS、原始与压缩文件字节数，才能判断某个参数提升是否符合日成本和机器预算。

16.3 表达能力上限

在不增加输入信息的前提下，本方案可以可靠表达：

- 角色随位置进入明暗区和环境色区；
- 可见几何造成的遮挡与近场漏光抑制；
- 角色主法线转向带来的正面、侧面和背面受光变化；
- 原画面已经表达出的直接/间接环境光；
- 被 LDR 压缩的局部发光体对角色新增的直接光；
- Lambert 身体隆起形成的低频体积感。

它不能可靠表达：

- 背景不可见侧真实存在但画面毫无线索的光源；
- 正确的镜面反射、头发高光和各向异性材质；
- 超出单张深度的真实三维穿行和背面碰撞；
- 角色对背景的动态反弹、动态阴影重绘和多角色互反射；
- 绝对物理 nit 与现实摄影相机参数。

这些不是继续调参数就能突破的误差，而是当前输入的信息上限。若以后需要突破，必须增加法线/材质、额外视图、人工光源或完整三维几何中的至少一种。

17. 最终成立的理论链

整套方法可以压缩为下面这一条没有断点的链：

$$C_{ldr} \xrightarrow[\text{scene EV}]{EOTF} L_0 \xrightarrow[\text{gain EV}]{split} (L_0, \Delta L_e) \quad (54)$$

$$(s, D, K_{pseudo}) \xrightarrow{\Pi_{pseudo}^{-1}} S_{vis}, O_{light}, q \quad (55)$$

$$(q, \omega) \xrightarrow{pseudo\ RT} \text{original hit else fold hit else } \bar{J} \quad (56)$$

$$T + \Delta L_e^{NEE} \xrightarrow{\int_{\Omega^+} \cos \theta d\omega} E(q, n) \xrightarrow{\rho/\pi} L_{char} \xrightarrow{shared\ tonemap} C_{display}. \quad (57)$$

离线 reference 直接计算到式 (57)；运行时版本只是在 $E(q, n)$ 这一层用 L2 球谐与空间 probe 压缩。二者的物理假设与能量账本完全相同。

这就是本项目在当前数据边界内能达到的表达能力上限：它不能凭空知道被遮住的真实世界，却可以让所有已知信息在正确的伪世界坐标中参与受光，把未知信息限制在可见、可调、可回退的补全层中。对二维纸片角色而言，这已经足以稳定产生暗部、环境色、背光、局部暖光、遮挡与身体法线梯度，而不增加角色动画或场景美术资源。

参考与现有项目决策

- 原始推导：《伪世界角色照明：从精确辐射传输到全部近似的推导》（本稿保留其正确的伪世界、terminal radiance、final gather 与 SH 主链，并修正归一化、闭包和误差边界）。
- 项目决策：[二维场景辐射度还原与发光增益管线定稿](#)。
- 接入规划：[角色照明烘焙接入游戏 - 规划](#)。
- Ravi Ramamoorthi, Pat Hanrahan, [An Efficient Representation for Irradiance Environment Maps](#), SIGGRAPH 2001。

源文档：file:///Users/dannyteng/AIWork/GameDraft/artifact/Design/伪世界角色照明-修正版完整推导-2026-07-21.md